EPOCH

Taiwanese Bankruptcy Prediction

Handling Imbalance with Recall-Focused Optimization

쨍쨍 : 김서연, 오지송 | Mar 31, 2026

FEVER DAY

Context

01. Problem Definition
02. Key Strategy
03. Data Understanding (EDA)
04. Feature Engineering
05. Model Design
06. Optimization
07. Evaluation Strategy
08. Results
09. Model Interpretation
10. Final Insight

01. Problem Definition

01. Problem Definition

Taiwan Bankruptcy Prediction

1

평가 지표

F2 Score

$$F2 = \frac{(1+2^2)\cdot Precision \cdot Recall}{2^2 \cdot Precision + Recall}$$

Recall이 Precision보다 더 중요하게 반영됨

F2는 Recall을 훨씬 더 중요하게 본다.

Recall을 좀 더 챙기되, Precision도 최소한 유지하는 방향

2

데이터 특성

Class Imbalacne

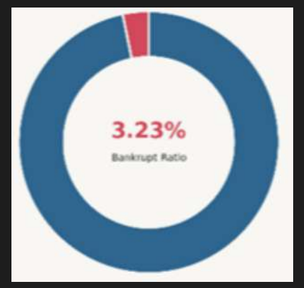

극심한 클래스 불균형

3

주요 과제

Key Challenges

Extreme Class Imbalance

파산 기업 비율이 약 3%로 매우 낮아

모델이 대부분을 정상 기업으로 예측하는 경향 발생

Recall-Precision Trade-off

Recall을 높이면 False Positive 증가

Precision 유지와의 균형 필요

01. Problem Definition

Taiwan Bankruptcy Prediction

F2 기반이므로 Recall 중심 전략 설계

평가 지표
F2 Score

$$F2 = \frac{(1+2^2)\cdot Precision \cdot Recall}{2^2 \cdot Precision + Recall}$$

Recall이 Precision보다 더 중요하게 반영됨

F2는 Recall을 훨씬 더 중요하게 본다.

Recall을 좀 더 챙기되, Precision도 최소한 유지하는 방향

데이터 특성
Class Imbalacne

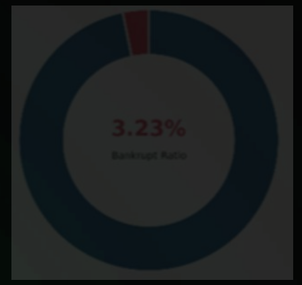

극심한 클래스 불균형

주요 과제
Key Challenges

Extreme Class Imbalance

파산 기업 비율이 약 3%로 매우 낮아

모델이 대부분을 정상 기업으로 예측하는 경향 발생

Recall-Precision Trade-off

Recall을 높이면 False Positive 증가

Precision 유지와의 균형 필요

02. Key Strategy

02. Key Strategy

01 **Recall-Oriented Optimization** F2 metric에 맞춰 파산 기업 탐지율(Recall) 극대화

02 **Imbalance Handling** SMOTE 및 scale_pos_weight를 활용하여 소수 클래스 학습 강화

03 **Ensemble Modeling** LightGBM, XGBoost 기반 앙상블 구성 → 모델 간 예측 안정성 확보

04 **Hard Voting Strategy** 다수 모델의 예측을 결합하여 robust한 최종 예측 수행

05 **Decision Boundary Optimization** 기본 threshold(0.5)가 아닌 F2 기준 최적 threshold 탐색

03. Data Understanding (EDA)

03. Data Understanding (EDA)

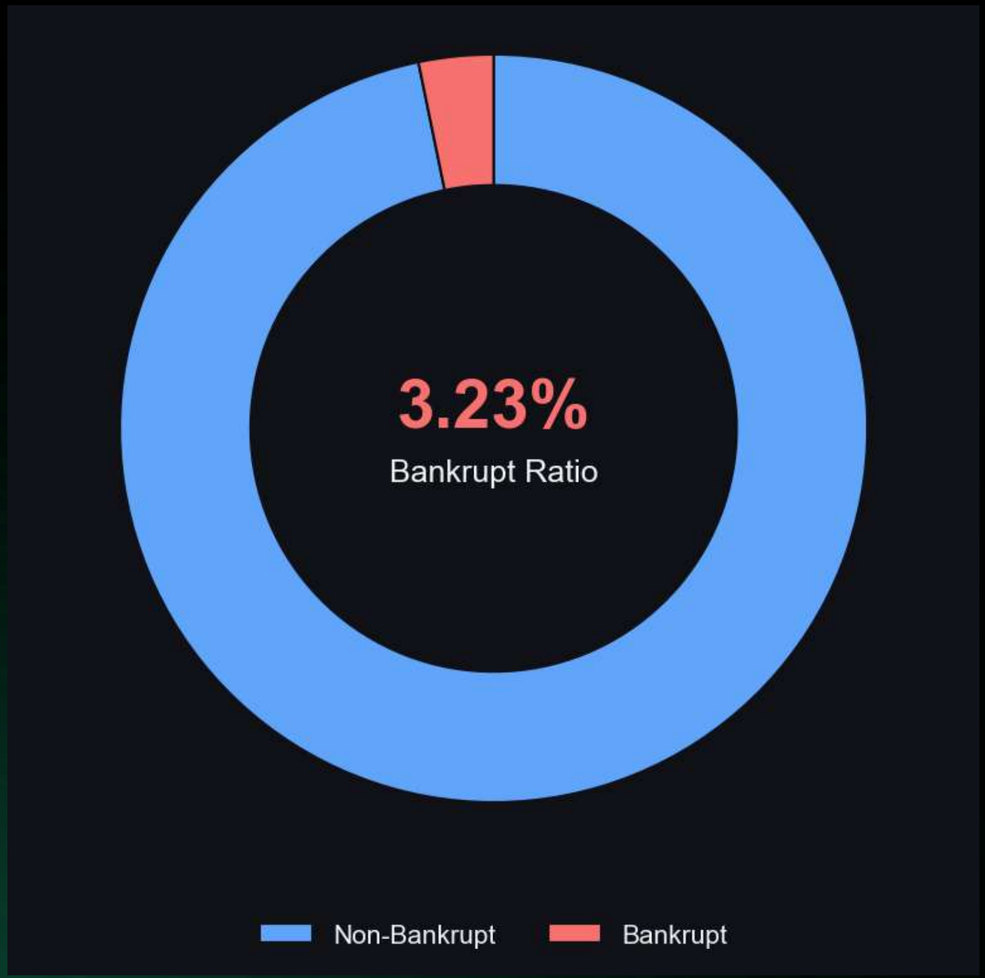

Severe Class Imbalance

- 파산 기업 비율 약 3%
- 모델이 대부분을 0으로 예측해도 높은 accuracy 가능

Recall 중심 평가

(F2 Score 최적화)

Imbalance handling

- SMOTE 적용
- class weight
- scale_pos_weight 활용

03. Data Understanding (EDA)

클래스 간 차이가 명확
일부 변수에서 gap 큼

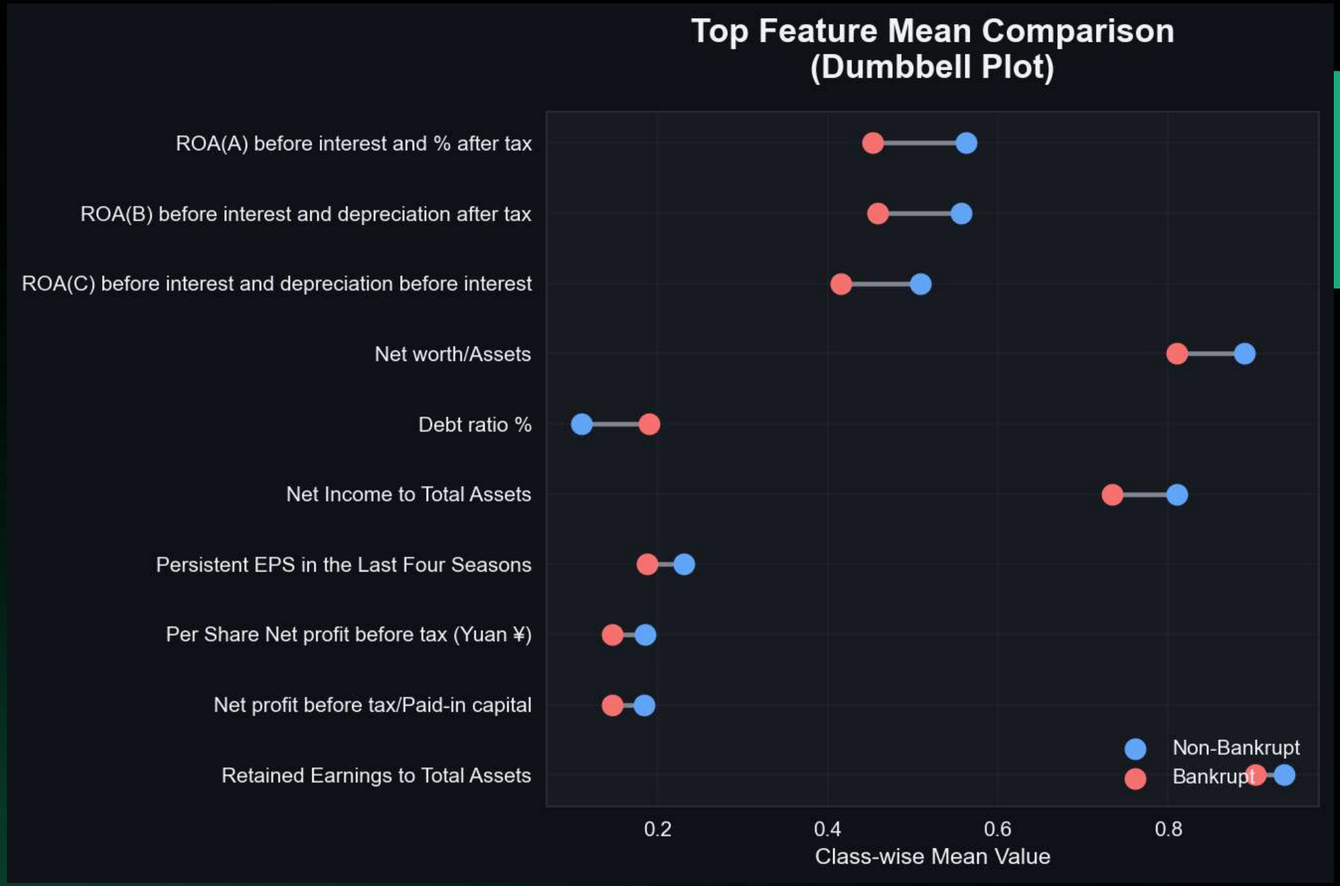

Clear Separation Between Classes

- 일부 변수에서 두 클래스 간 차이가 매우 큼
- 완전히 겹치지 않는 구간 존재

Ensemble 전략

(Hard Voting)

다양한 모델 조합으로

안정성 확보

(Tree + Boosting)

03. Data Understanding (EDA)

Key Financial Signals of Bankruptcy

- 부채 관련 지표 ↑ : 파산 가능성 증가
- 수익성 지표 ↓ : 파산 가능성 증가
- 특정 변수에서 극단적인 값 발생

Threshold tuning

이상치/극단값을 놓치지 않는 모델 선택

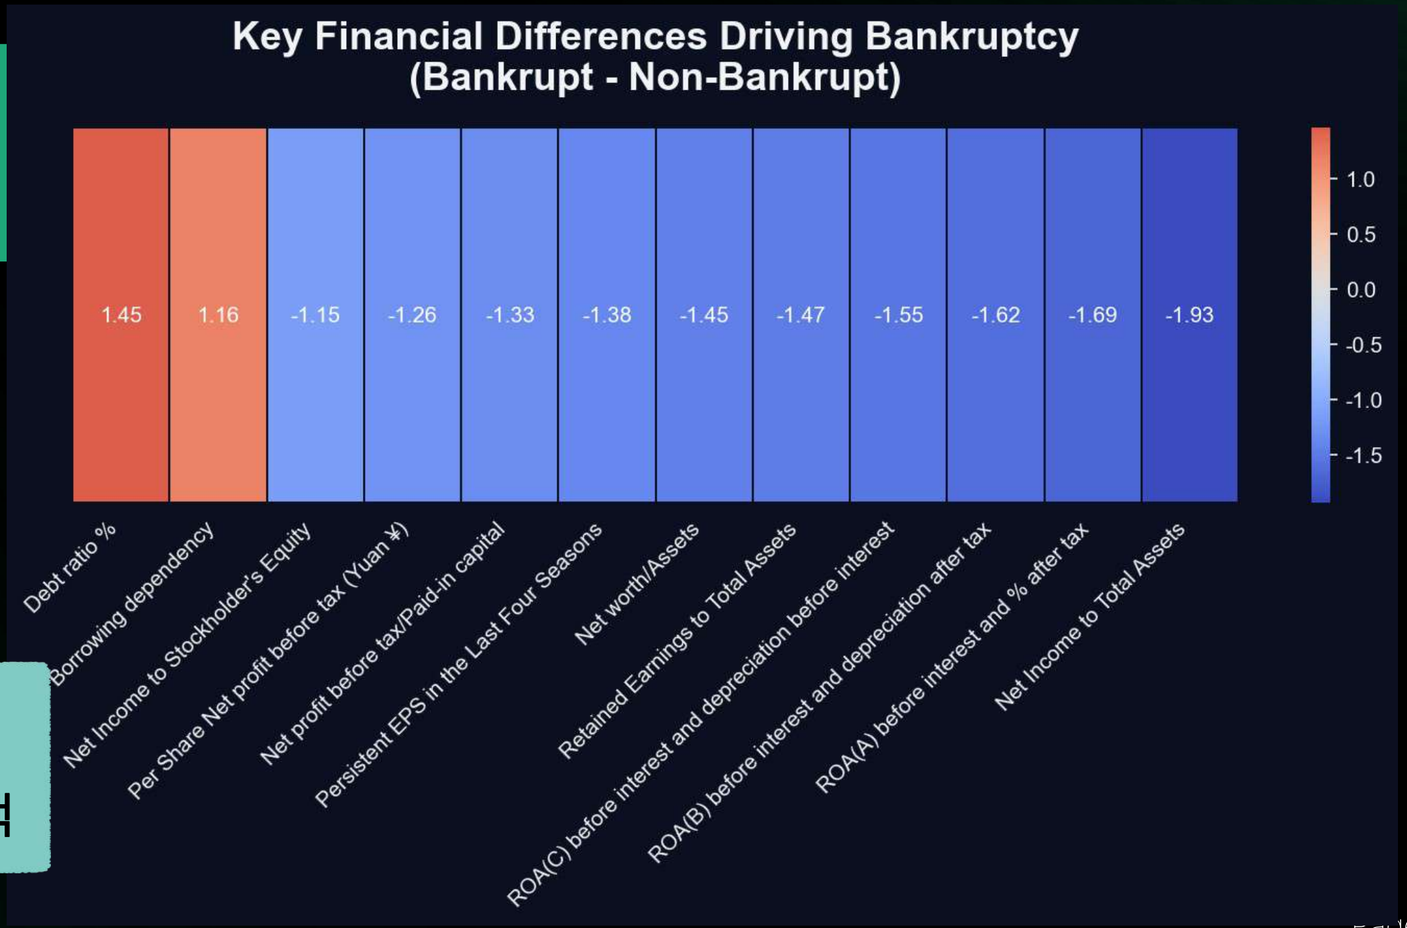

04. Feature Engineering

04. Feature Engineering

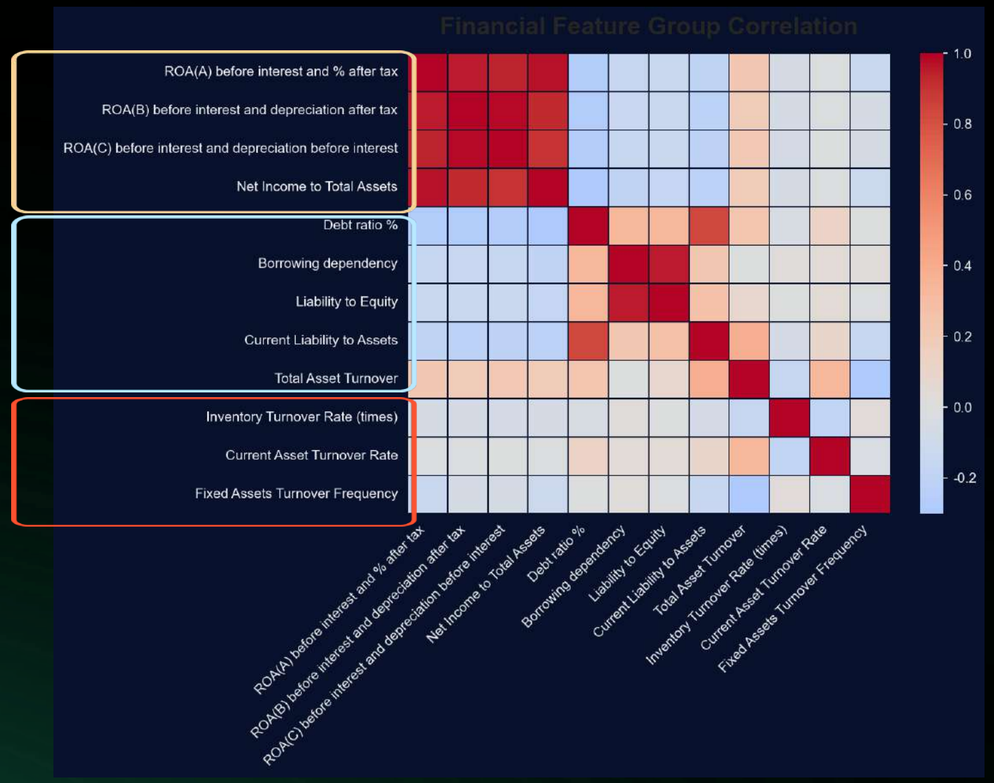

Financial Feature Group Correlation

수익성 변수끼리 강하게 묶임

ROA(A), ROA(B), ROA(C), Net Income to Total Assets

각각이 완전히 독립적인 정보라기보다
수익성이라는 공통된 신호를 공유하는 변수들

부채/레버리지 변수도 하나의 그룹을 형성

Debt ratio %, Borrowing dependency,
Liability to Equity, Current Liability to Assets

파산은 단순히 이익이 낮아서만이 아니라
부채 구조 자체가 취약해지는 방향과 함께 나타남

활동성/회전율 변수는 또 다른 축

Total Asset Turnover, Inventory Turnover, Fixed Assets Turnover

"기업 운영 효율성 혹은 자산 활용 패턴"을 나타내는 별도 그룹

04. Feature Engineering

변수 그룹화 기준

Financial Feature Group Correlation

수익성 변수끼리 강하게 묶임

Profitability (수익성)
→ ROA 계열, 순이익 관련 지표, EPS 계열

부채/레버리지 변수도 하나의 그룹을 형성

Leverage / Debt (부채 구조)
→ 부채비율, 차입 의존도, 자본 대비 부채, 유동부채 관련 지표

활동성/회전율 변수는 또 다른 축

Efficiency / Turnover (활동성)
→ 자산 회전율, 재고 회전율, 고정자산 회전율

04. Feature Engineering

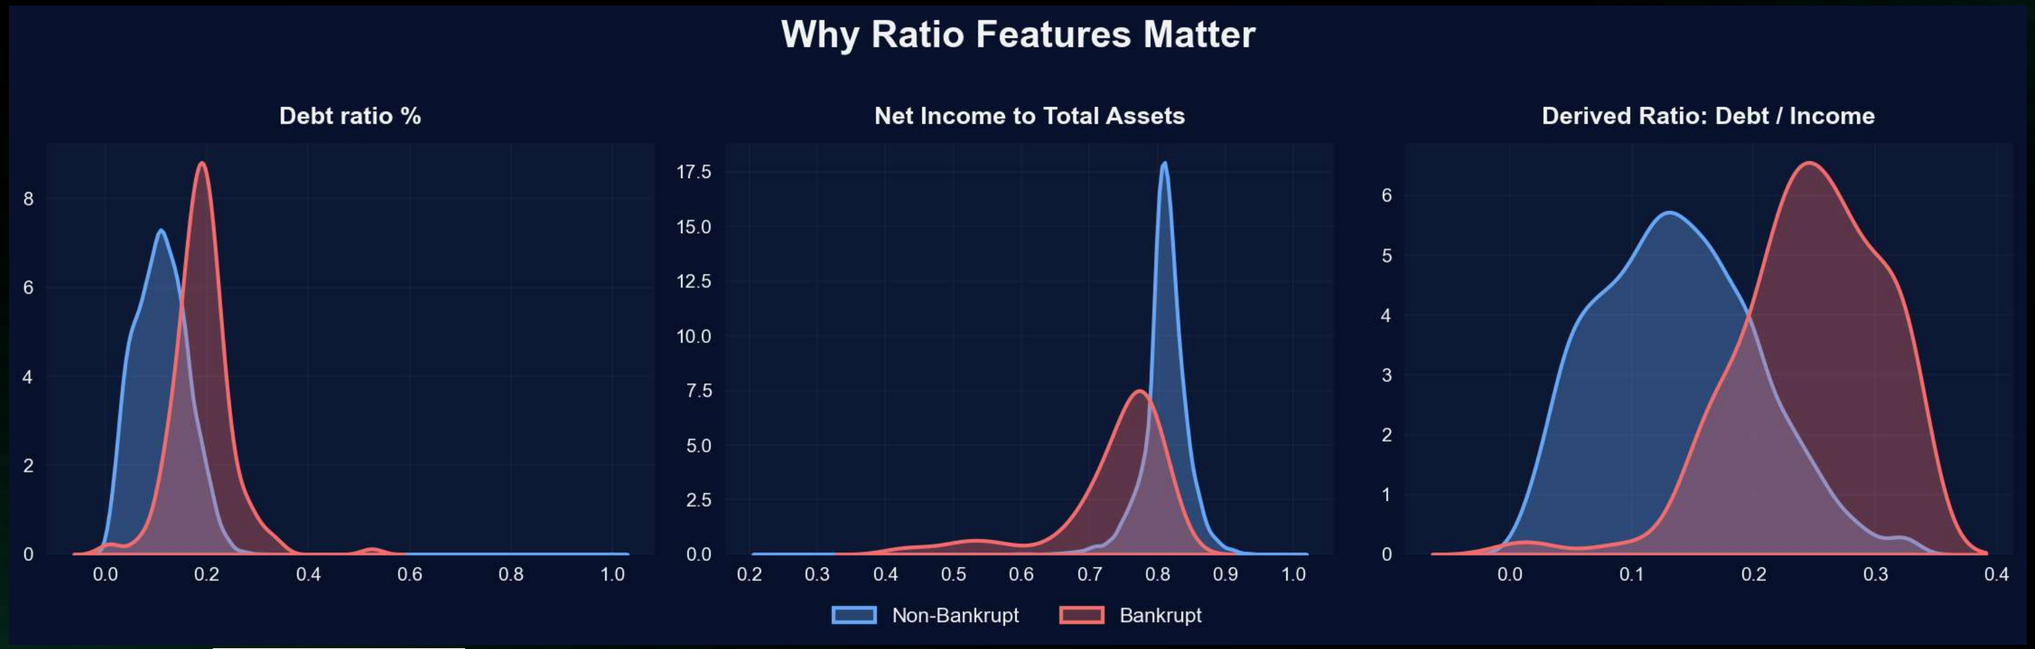

Debt ratio %

파산 기업 분포가 상대적으로 오른쪽
즉, 파산 기업일수록 부채 비율이 높음
부채가 높은 기업이 무조건 파산 X
기업 규모나 수익성과 함께 봐야 좋음

Net Income to Total Assets

비파산 기업은 상대적으로 수익성이 높고
파산 기업은 낮은 쪽으로 이동
수익성 저하 역시 중요한 신호

Debt / Income ratio가 더 분리도가 좋음

Debt ratio %와 Net Income to Total Assets
를 따로 볼 때보다 **그 둘의 관계를 반영한**
Debt / Income 파생변수에서
두 클래스가 더 잘 갈라짐

04. Feature Engineering

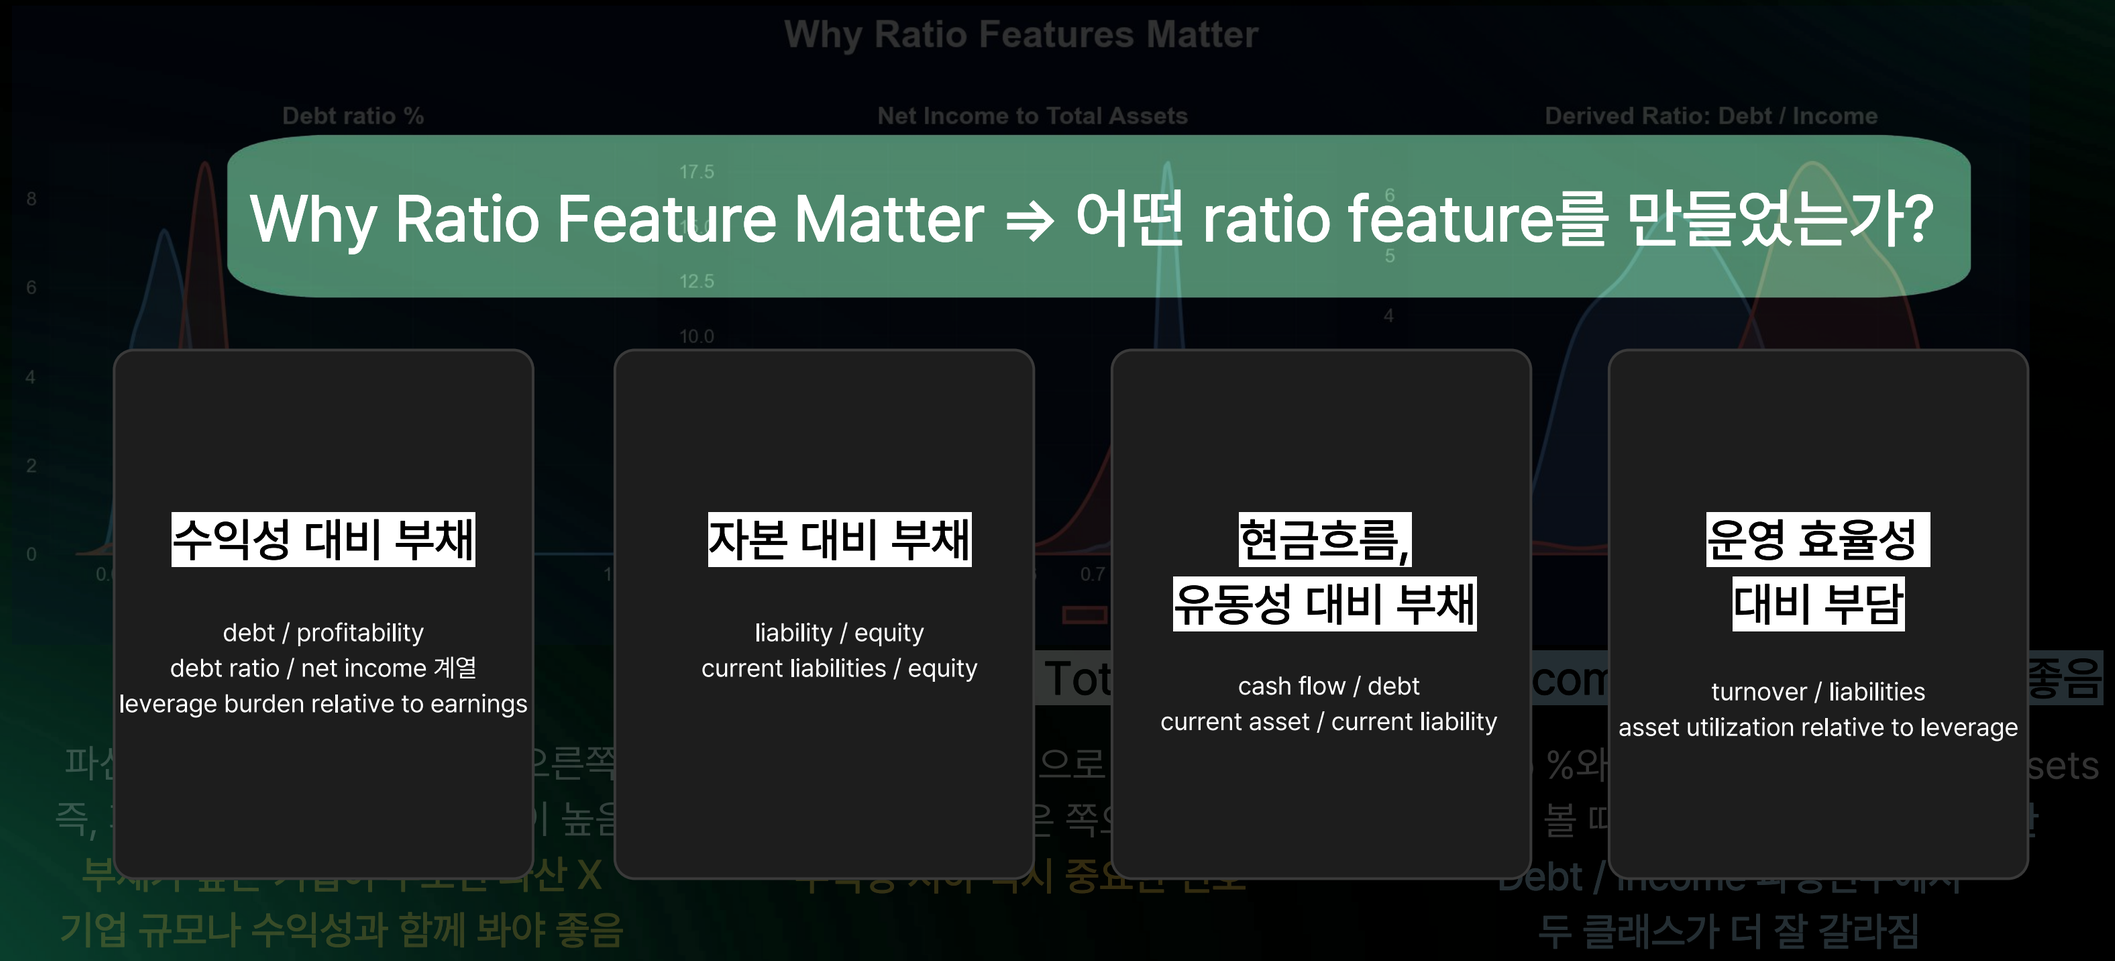

Why Ratio Feature Matter ⇒ 어떤 ratio feature를 만들었는가?

수익성 대비 부채

debt / profitability
debt ratio / net income 계열
leverage burden relative to earnings

자본 대비 부채

liability / equity
current liabilities / equity

현금흐름, 유동성 대비 부채

cash flow / debt
current asset / current liability

운영 효율성 대비 부담

turnover / liabilities
asset utilization relative to leverage

04. Feature Engineering

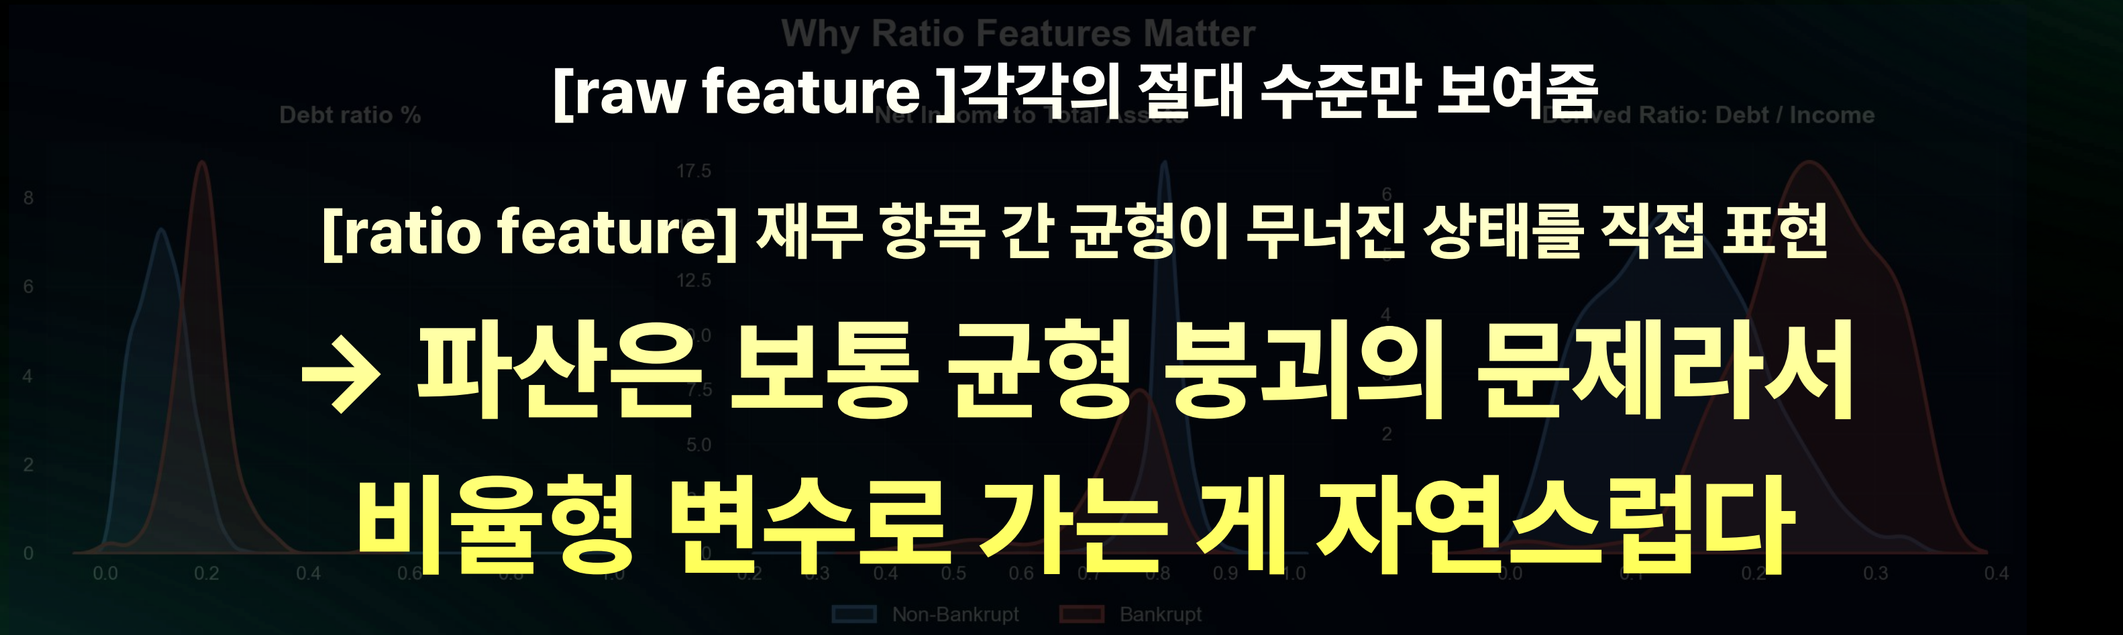

[raw feature]각각의 절대 수준만 보여줌

[ratio feature] 재무 항목 간 균형이 무너진 상태를 직접 표현

→ 파산은 보통 균형 붕괴의 문제라서 비율형 변수로 가는 게 자연스럽다

Debt ratio %

파산 기업 분포가 상대적으로 오른쪽
즉, 파산 기업일수록 부채 비율이 높음
부채가 높은 기업이 무조건 파산 X
기업 규모나 수익성과 함께 봐야 좋음

Net Income to Total Assets

비파산 기업은 상대적으로 수익성이 높고
파산 기업은 낮은 쪽으로 이동
수익성 저하 역시 중요한 신호

Debt / Income ratio가 더 분리도가 좋음

Debt ratio %와 Net Income to Total Assets
를 따로 볼 때보다 그 둘의 관계를 반영한
Debt / Income 파생변수에서
두 클래스가 더 잘 갈라짐

04. Feature Engineering

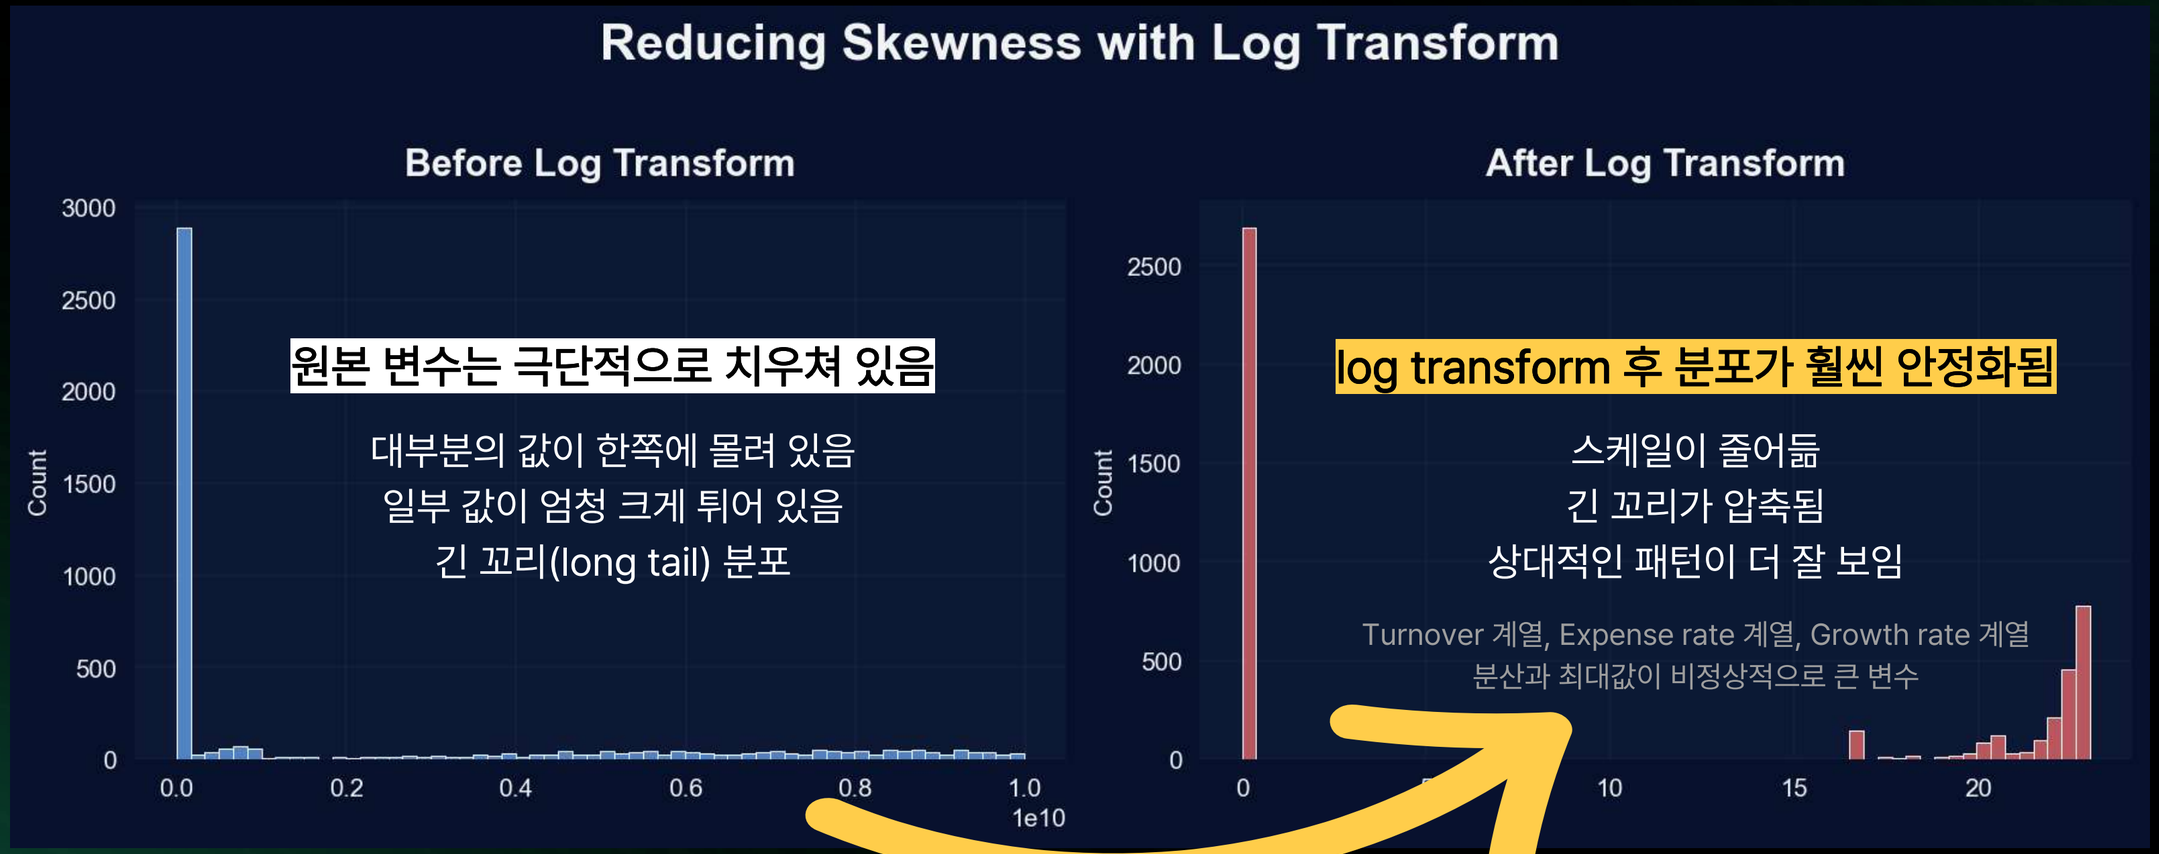

04. Feature Engineering

기업이 자산을 통해 얼마나 이익을 내는가
파산 기업은 여기서 전반적으로 약한 모습을 보임

Profitability (수익성)

ROA(A), ROA(B), ROA(C)
Net Income to Total Assets
Persistent EPS

↓

Ratio Features

수익성 그룹을 하나의 구조로 묶어 해석
부채와 결합한 ratio feature 생성

기업이 얼마나 부채에 의존하고 있는가
자본 구조가 얼마나 취약한가

Leverage / Debt (부채 구조)

Debt ratio %
Borrowing dependency
Liability to Equity

↓

Domain-based Grouping

부채 관련 변수끼리 묶어 핵심 구조로 사용
수익성/자본과의 관계를 반영한 파생변수 생성

기업이 자산을 얼마나 효율적으로 활용하는가
하지만 일부 변수는 왜도와 스케일 문제가 큼

Efficiency / Turnover (활동성)

Inventory Turnover
Total Asset Turnover
Fixed Assets Turnover

↓

Log Transform

활동성 그룹은 유지하되
왜도 완화를 위해 log transform 적용
원본 대비 안정된 신호로 재가공

05. Model Design

05. Model Design

Why Tree-based Boosting?

비선형 관계 학습 가능	변수 간 상호작용 반영 가능	이상치/스케일 차이에 비교적 강함	tabular financial dataset에 적합

Model Comparison

LightGBM과 XGBoost

→ tabular 데이터에서 높은 표현력과 안정성을 동시에 제공

Logistic Regression

→ 비선형 관계를 충분히 반영 X

	Tabular 적합성	비선형 관계 학습	실험 속도	안정성	불균형 대응 유연성	앙상블 적합성
LightGBM	5	5	5	4	4	5
XGBoost	5	5	3	5	5	5
Logistic Regression	3	2	4	3	2	3

05. Model Design

Performance Comparison

F2 기준에서

Tree-based 모델이

기존 모델 대비 성능 향상

→ 파산 기업을 놓치지 않는 방향으로

모델이 개선되었음을 의미

05. Model Design

Precision vs Recall

Recall 중심의 성능 향상이

F2 개선의 핵심 요인

→ 파산 예측에서는

false negative를 줄이는 것이 중요

→ recall에 더 가중치를 둠

→ 실제로 recall이 높은 모델일수록

F2 score도 함께 개선되는 경향

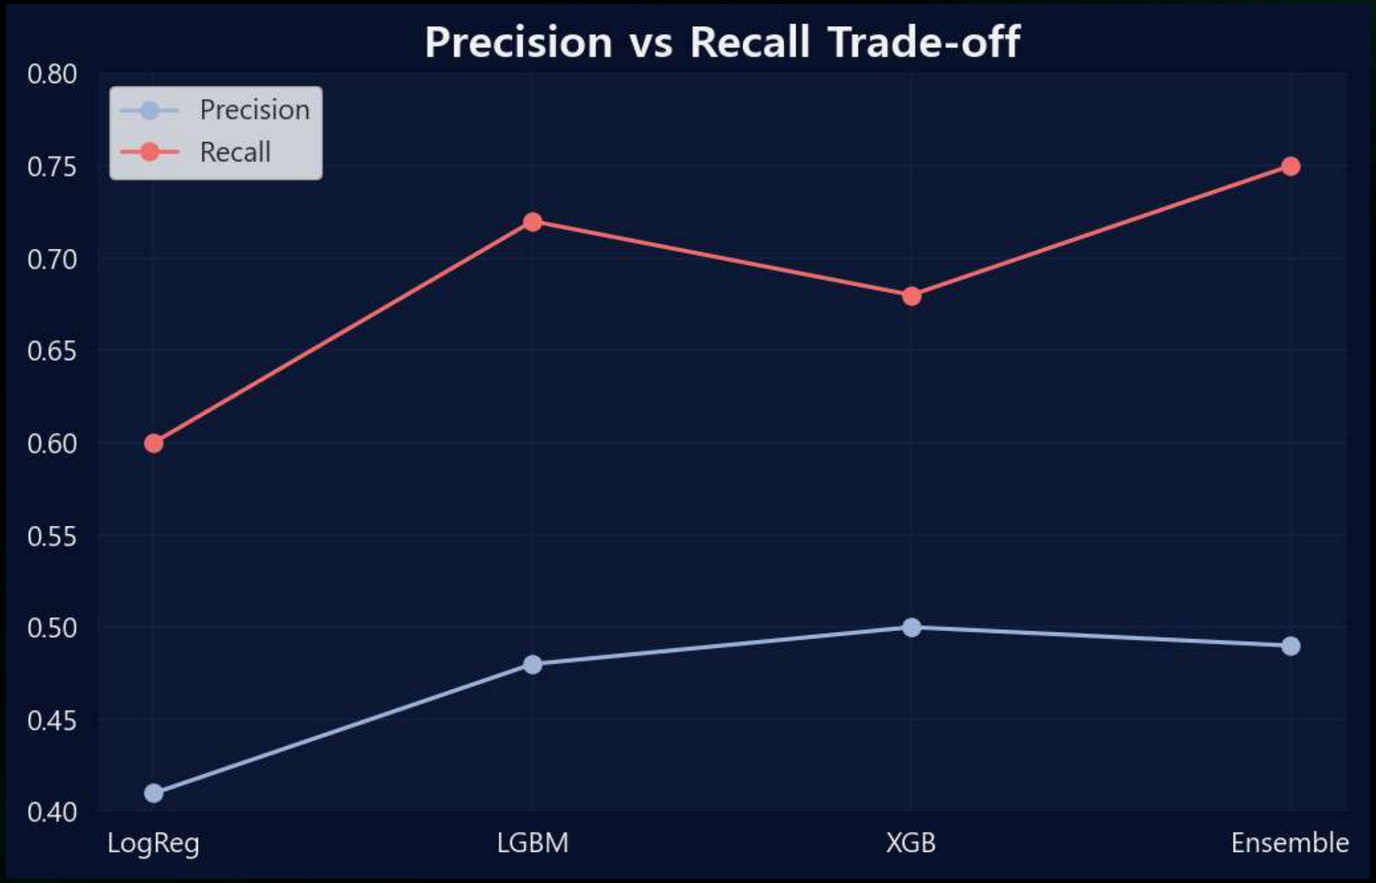

05. Model Design

Validation & Ensemble

단일 모델의 변동성을 줄이기 위해 앙상블 전략 적용

→ Stratified 5-Fold를 사용

→불균형 데이터에서도 안정적인 검증

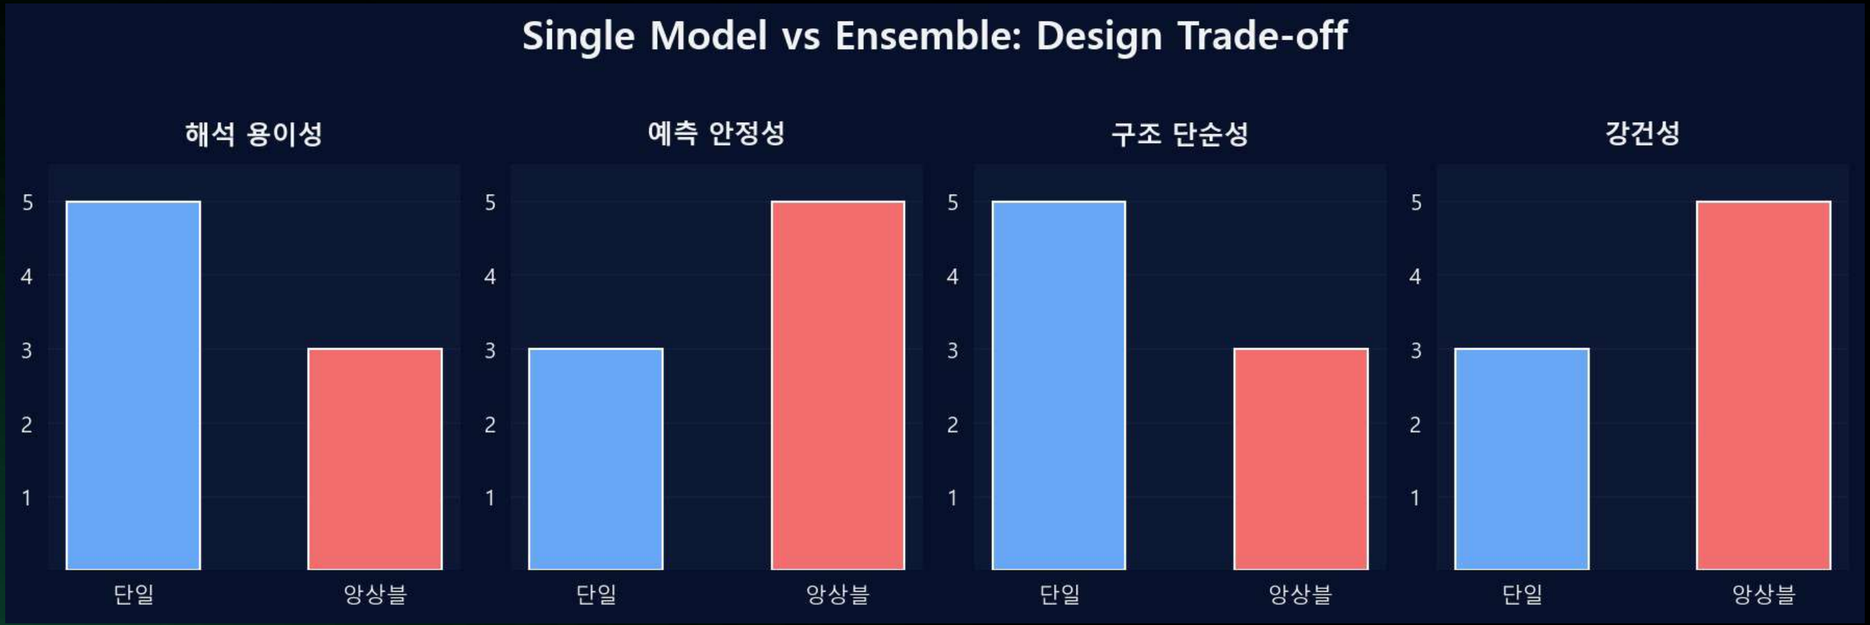

06. Optimization

06. Optimization

모델 자체보다
threshold와 decision rule이
성능에 더 큰 영향을 미침

06. Optimization

모델 파라미터 최적화 기본 성능 개선

OPTUNA

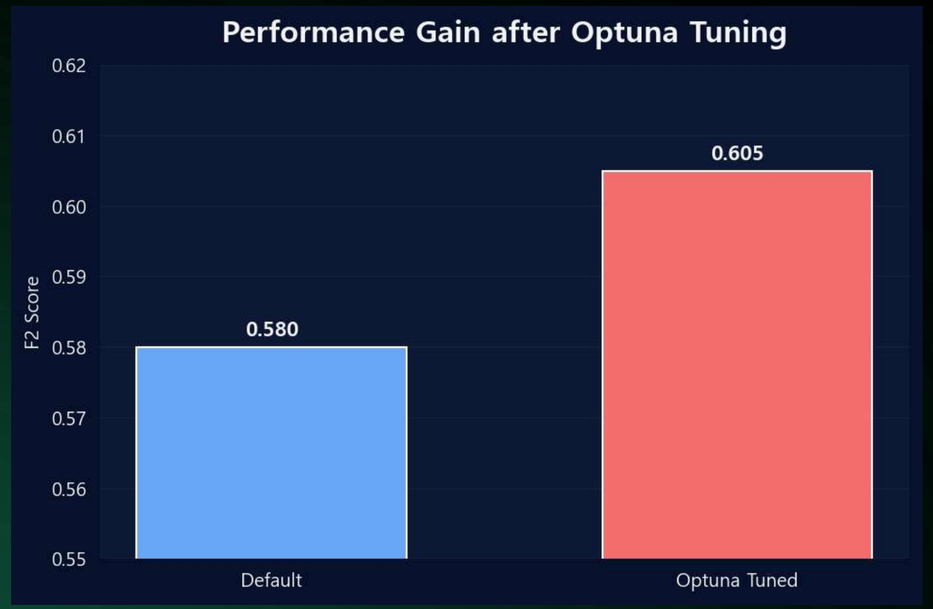

Data-level (SMOTE) vs Model-level (Weighting)

SMOTE와 scale_pos_weight는 상호보완적 역할

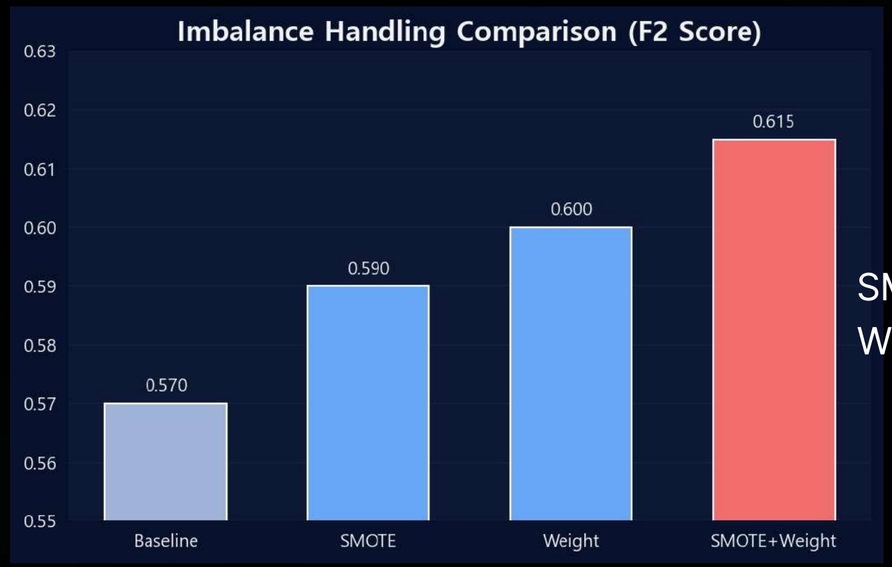

SMOTE → recall 개선
Weight → 학습 안정성
결합 시 최적 성능

07. Evaluation Strategy

07. Evaluation Strategy

모든 성능 평가는 OOF 기반으로 수행하여 과적합을 방지

Stratified 5-Fold

Out-of-Fold (OOF) prediction을

활용한 신뢰성 있는 평가

F2 기준 threshold 탐색

OOF prediction을 기반으로

threshold 최적화

OOF prediction

클래스 비율을 유지한 Stratified 5-Fold CV

08. Results

08. Result

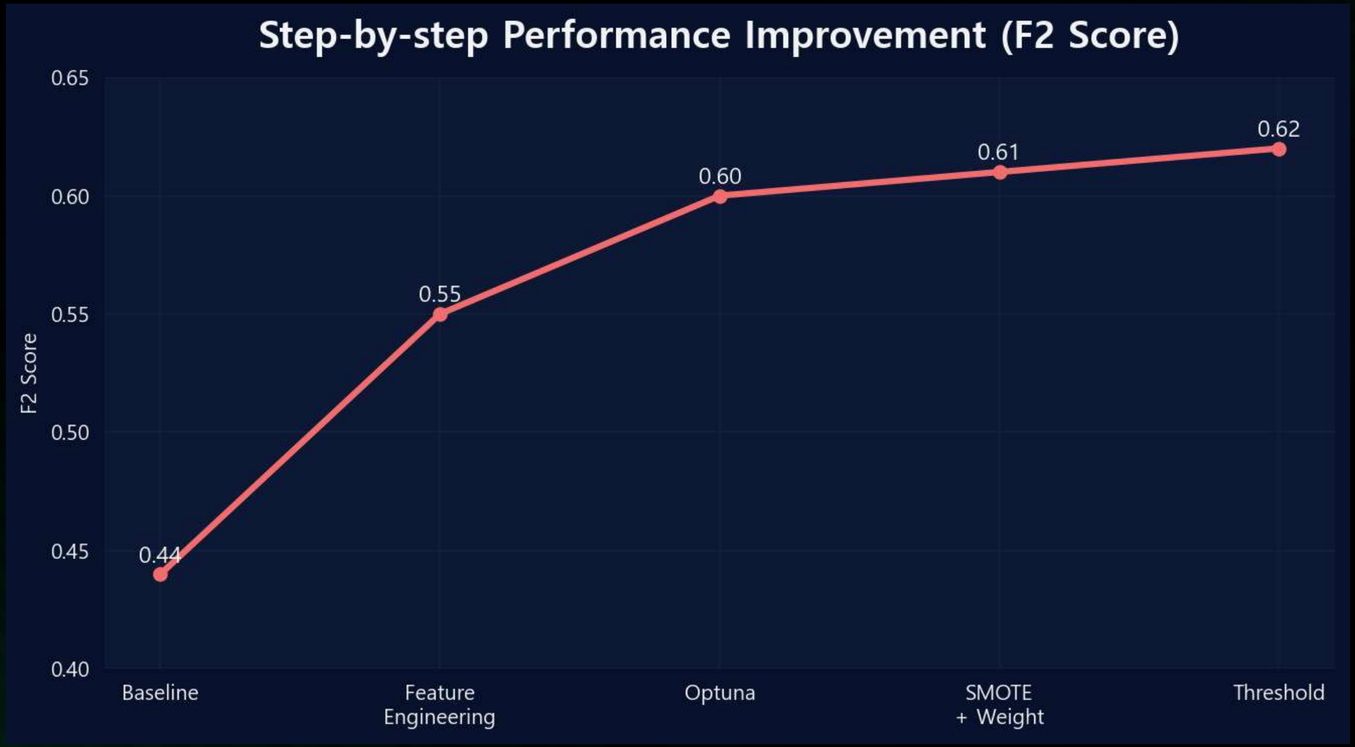

성능 향상은 단일 기법이 아니라 단계적 개선의 결과

→ 특히 가장 큰 성능 개선은 feature engineering과 threshold tuning에서 발생

09. Model Interpretation

09. Model Interpretation

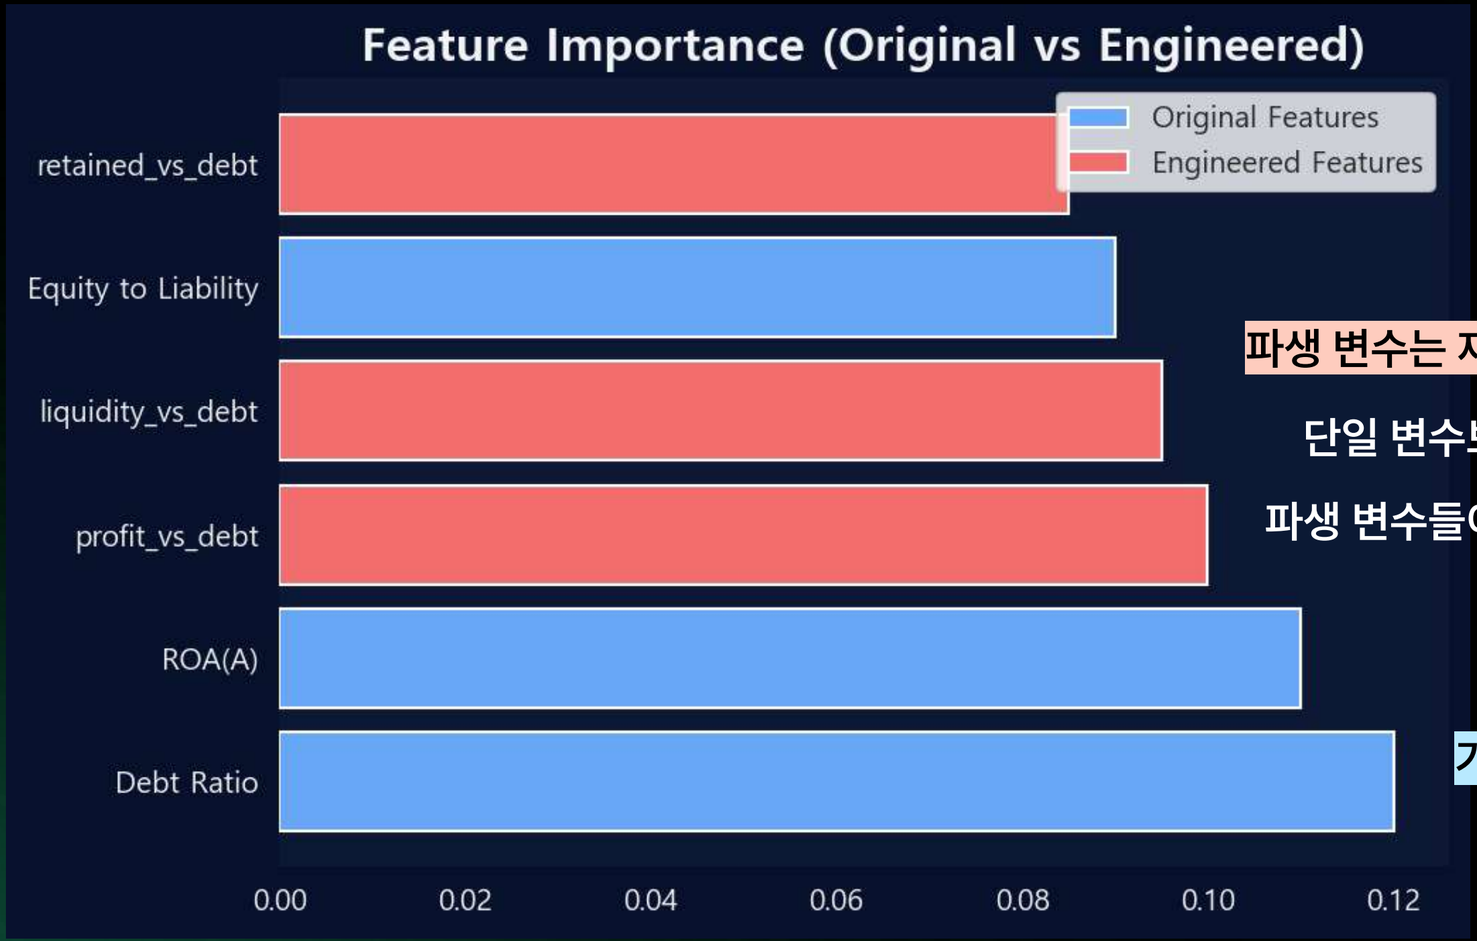

파생 변수는 재무 구조의 상호작용을 반영하며 성능 개선에 기여

단일 변수보다 변수 간 관계가 더 중요한 패턴으로 확인됨

파생 변수들이 상위 중요도에 포함되며 의미 있는 신호로 작용

기존 중요 변수 (Debt ratio, ROA 등)

10. Final Insight

10. Final Insight

Final Insight

- F2 metric에서는 threshold tuning이 성능의 핵심 요소
- Recall은 무작정 높이는 것이 아니라 제어된 방식으로 확장
- 모델 자체보다 decision strategy가 더 큰 영향을 미침

Key Lessons

- Feature engineering이 가장 큰 성능 개선을 유도
- Imbalance handling은 필수 조건
- Validation 전략이 결과의 신뢰도를 결정
- Threshold tuning이 최종 성능을 완성

Limitations & Future Work

- Recall 중심 최적화의 한계 (false positive 증가)
- Threshold tuning의 데이터 의존성
- Cost-sensitive learning 적용

EPOCH

감사합니다.

Handling Imbalance with Recall-Focused Optimization